INSA INSTITUT NATIONAL DES SCIENCES APPLIQUÉES ROUEN NORMANDIE
Département STPI

2024/2025

PROJET DE STATISTIQUES D'M8

Des chiffres et des drogues

Étudiants

Camille	POLLET	camille.pollet@insa-rouen.fr
Maïssa	BEN SETHOUM	maissa.bensethoum@insa-rouen.fr
Morgan	GOUZOU–HELLOT	morgan.gouzou–hellot@insa-rouen.fr

22 septembre 2026

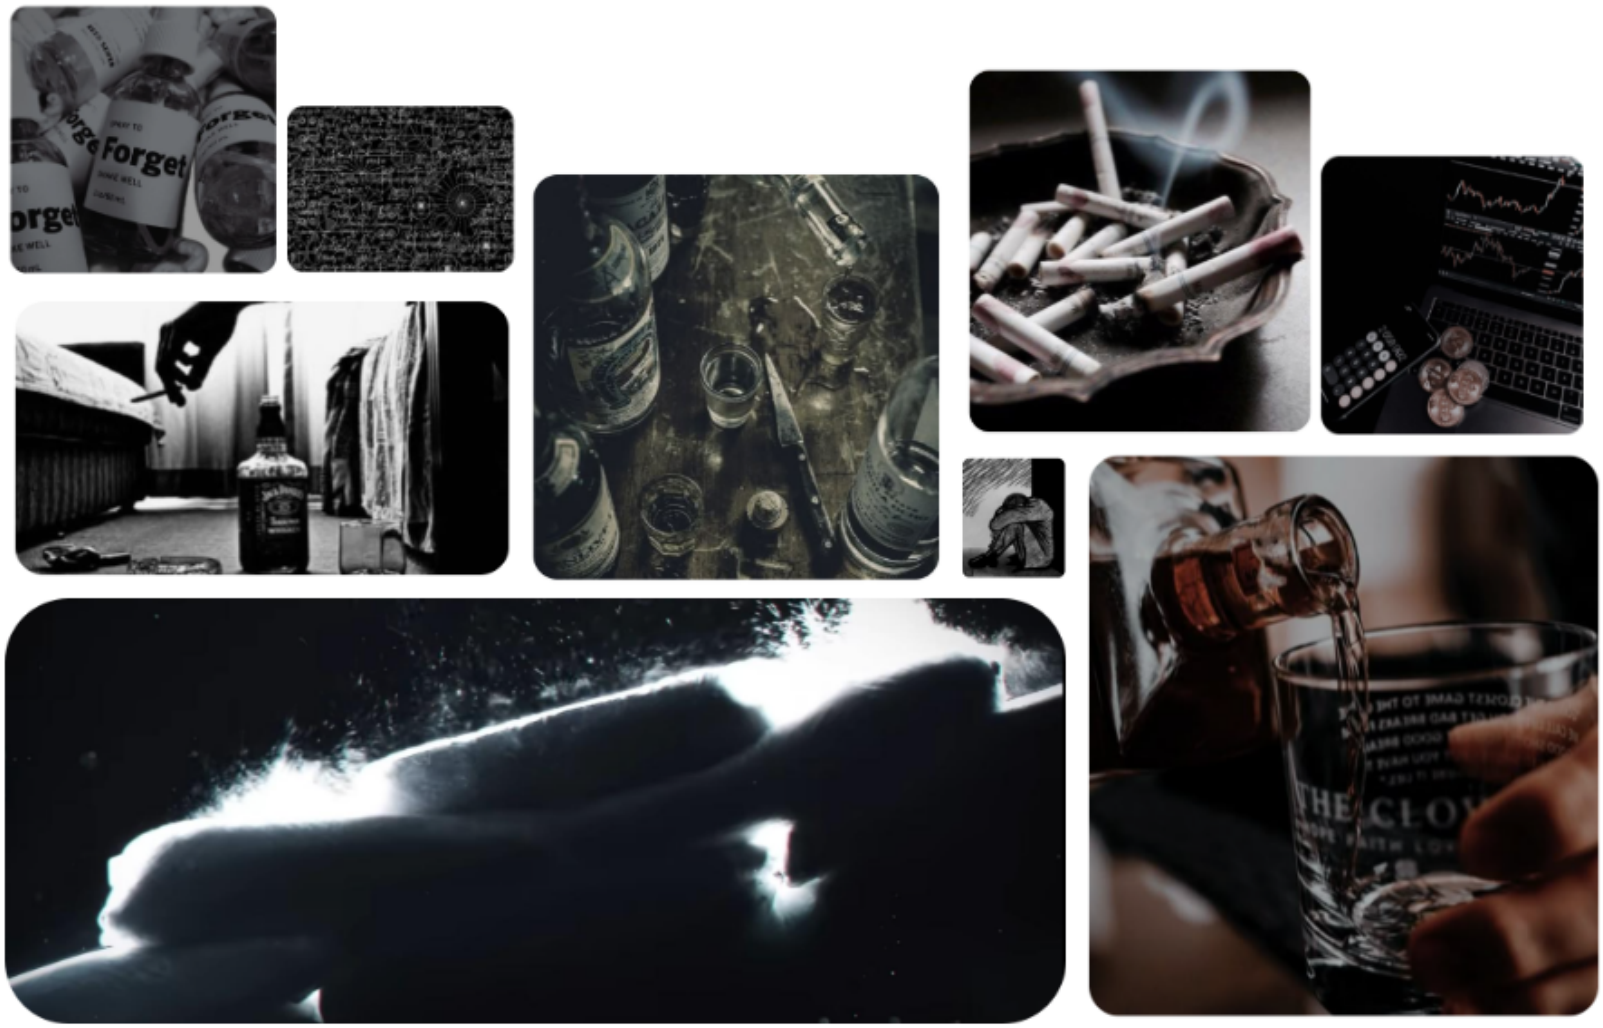


Table des matières

Introduction **2**

1 Description des données **3**
1.1 Introduction et présentation générale du dataset . . . 3
1.2 Description des variables . . . 3
1.2.1 Variables sociodémographiques . . . 3
1.2.2 Variables psychométriques . . . 3
1.2.3 Variables de consommation de drogues . . . 4
1.3 Préparation des données et premiers constats . . . 4

2 Régression et classification **5**
2.1 Régression linéaire multiple . . . 5
2.1.1 Régression multiple générale . . . 5
2.1.2 Régression sur les variables psychologiques . . . 5
2.1.3 Régression sur les variables sociodémographiques . . . 5
2.1.4 Conclusion partielle . . . 6
2.2 Régressions simples . . . 6
2.2.1 Impulsivité et recherche de sensation forte . . . 6
2.2.2 Cannabis et Impulsivité . . . 7
2.2.3 Chocolat et impulsivité . . . 7

3 Tests statistique **9**
3.1 Impulsivité et recherche de sensation forte . . . 9
3.2 Cannabis et Impulsivité . . . 9
3.3 Chocolat et impulsivité . . . 10

Conclusion **11**

Annexes **12**

Introduction

Depuis les premières civilisations, les sociétés humaines ont entretenu des rapports complexes avec les substances psychoactives. Qu'elles soient utilisées à des fins médicinales, rituelles, récréatives ou pour fuir une réalité trop pesante, les drogues traversent les époques tout en soulevant les mêmes questions : qui en consomme, pourquoi, dans quel contexte, et avec quelles conséquences ?

À l'ère des données massives et de la modélisation statistique, il devient possible d'aborder ces questions non seulement par des récits ou des opinions, mais à travers l'analyse rigoureuse de profils et de comportements. C'est dans ce cadre que s'inscrit notre projet, qui se fonde sur un jeu de données riche, mêlant caractéristiques sociodémographiques, traits de personnalité, et habitudes de consommation d'une trentaine de substances, allant de l'alcool et la caféine à des drogues plus controversées, en passant même par le chocolat et un médicament fictif.

Loin de l'image parfois caricaturale du "profil type" du consommateur, ces données nous offrent l'opportunité de croiser les regards : âge, genre, éducation, impulsivité, ouverture à l'expérience. Tous ces éléments pourraient jouer un rôle dans les usages individuels. Notre objectif est donc d'examiner dans quelle mesure ces variables peuvent expliquer, voire prédire, certains comportements liés aux drogues.

Ainsi, notre rapport s'articulera en trois grandes parties : une description détaillée des données, une analyse par régression pour tenter de prédire certains comportements à partir de variables explicatives, et enfin, des tests statistiques pour valider (ou non) nos hypothèses.

À une époque où les discours sur les drogues oscillent entre criminalisation, banalisation et enjeux de santé publique, nous espérons que cette étude, bien que modeste, contribuera à mieux comprendre ce phénomène complexe à travers des données.

1 Description des données

1.1 Introduction et présentation générale du dataset

Ce projet d'analyse statistique repose sur une base de données publique issue d'une étude menée en 2015, centrée sur les comportements de consommation de substances psychoactives en lien avec divers facteurs sociodémographiques et psychologiques. L'objectif est d'identifier des tendances et des associations entre caractéristiques individuelles et consommation de drogues. L'étude combine des données quantitatives (âge, scores de personnalité) et qualitatives (origine ethnique, fréquence de consommation, etc.) afin de mieux comprendre les facteurs associés à ces comportements. Le dataset comprend 1 889 individus décrits par 31 variables. Chaque ligne correspond à un individu, caractérisé par des informations personnelles, sociodémographiques, des scores psychométriques évaluant plusieurs traits de personnalité, ainsi que par ses habitudes de consommation concernant 18 drogues différentes.

1.2 Description des variables

Les variables peuvent être regroupées en trois grandes catégories : sociodémographiques, psychométriques et comportementales (consommation).

1.2.1 Variables sociodémographiques

— `AGE` : variable qualitative ordinale regroupant les âges en 6 catégories

1. entre 18 et 24 ans
2. entre 25 et 34 ans
3. entre 35 et 44 ans
4. entre 45 et 54 ans
5. entre 55 et 64 ans
6. plus de 65 ans

Voir Annexe 7 pour la répartition de l'âge

— `GENDER` : homme ou femme

— `ETHNICITY` : variable nominale indiquant l'origine ethnique de l'individu (Blanc, Noir, Mixte, Asiatique, Autre).

— `COUNTRY` : pays de résidence parmi le Royaume-Uni, les États-Unis, l'Australie, le Canada, l'Irlande, la Nouvelle-Zélande et autres.

Voir Annexe 8 pour la répartition des pays et ethnies

D'après les histogrammes, on remarque que la majorité des personnes interrogées sont "blanches" et viennent principalement du Royaume-Uni et des États-Unis . Cette forte représentation rend plus difficile de tirer des conclusions fiables sur l'origine ethnique ou la provenance géographique dans l'analyse.

— `EDUCATION` : niveau d'éducation atteint, allant de « a quitté l'école avant 16 ans » jusqu'au doctorat.

Voir Annexe 9 pour la répartition du niveau d'éducation

Ces variables permettront d'explorer des tendances et des associations entre caractéristiques individuelles et comportements de consommation. Il est toutefois important de souligner qu'il ne s'agit en aucun cas de définir des profils types figés ou de tirer des conclusions causales : les corrélations observées ne traduisent pas nécessairement une relation de cause à effet, et l'interprétation de ces données doit rester prudente et respectueuse des enjeux éthiques liés à la stigmatisation potentielle des comportements individuels.

1.2.2 Variables psychométriques

Ces variables sont issues d'un test de personnalité basé sur le modèle des Big Five. Les scores sont standardisés :

Score	**Trait de personnalité**	**Signification**
Nscore	Névrosisme	Tendance à l'anxiété, à la dépression
Escore	Extraversion	Ouverture sociale, enthousiasme
Oscore	Ouverture	Imagination, curiosité, créativité
Ascore	Agréabilité	Altruisme, confiance envers les autres
Cscore	Conscience	Autodiscipline, organisation
Impulsiveness et SS	Sensation Seeking	Sensations fortes, impulsivité, comportements à risques

Ces scores sont essentiels pour explorer les mécanismes psychologiques potentiels derrière certaines consommations.

1.2.3 Variables de consommation de drogues

18 substances sont étudiées, parmi lesquelles :

— Produits légaux : Alcool, Nicotine, Caféine, Chocolat, Cannabis (dans certains pays).

— Produits illégaux ou réglementés : Cannabis (dans certains pays), Cocaïne, Héroïne, LSD, Ectasie, Magic Mushrooms, Amphétamines, etc.
Parmi les variables, on trouve une substance appelée SEMER. Après vérification, il s'agit d'un médicament fictif, le Semoran, supposé avoir des effets hallucinogènes. Ce produit étant illégal et très peu consommé, nous avons choisi de l'exclure de notre analyse.

Pour chaque substance, la fréquence de consommation est codée selon 7 modalités :

Code	Signification
CL0	Jamais consommé
CL1	Consommé il y a plus de 10 ans
CL2	Consommé dans l'année, mais pas récemment
CL3	Consommé dans les 30 derniers jours
CL4	Consommé dans la semaine
CL5	Consommé dans les 3 derniers jours
CL6	Consommé dans les 24 dernière heurs

Ces modalités ont été transformées en valeurs numériques allant de 0 à 6, pour permettre une analyse quantitative plus simple et précise.

1.3 Préparation des données et premiers constats

Un certain nombre d'opérations de nettoyage et de transformation ont été appliquées avant les analyses statistiques : la suppression de l'identifiant (ID, non informatif pour l'analyse), l'encodage numérique des modalités où les modalités textuelles (comme CL0, CL1, etc.) ont été converties en scores numériques, la standardisation des données où les variables de consommation ont été centrées et réduites afin de les comparer sur une même échelle et la création de matrices de corrélation pour identifier les substances dont la consommation est fortement liée.

Une première visualisation des corrélations entre les différentes substances révèle plusieurs associations fortes. Tout d'abord, la consommation de cannabis est fortement liée à celle de LSD et Magic Mushrooms (corrélation supérieure à 0.6). Ensuite, nous remarquons que le café, le chocolat et la nicotine présentent également des corrélations modérées à fortes entre elles. Et enfin, certaines substances rares comme l'héroïne ou le crack ne présentent que de faibles corrélations, ce qui suggère des profils de consommateurs plus marginaux ou isolés. Ces observations orientent déjà l'hypothèse qu'il existe des groupes de drogues consommées ensemble, volontairement ou non *(voir Annexe 10)*.

Une autre analyse a été menée à partir du graphique représentant la consommation moyenne de chaque drogue selon les tranches d'âge *(voir Annexe 11)*. Ce graphique met en évidence une tendance générale claire : plus l'âge augmente, moins la consommation est élevée. Par exemple, pour l'ecstasy, la moyenne de consommation est d'environ 4,5 chez les 18-24 ans, alors qu'elle chute à moins de 1 chez les plus de 65 ans. Cette évolution traduit probablement le fait que certaines drogues sont davantage associées à des usages festifs ou expérimentaux, plus fréquents chez les jeunes adultes.

Cependant, trois exceptions notables ressortent. La première concerne le chocolat, la seconde le café. Dans les deux cas, la consommation reste stable ou élevée quel que soit l'âge. Cela semble logique : il s'agit de substances socialement acceptées, largement consommées dans la vie quotidienne, indépendamment de l'âge. La troisième exception, plus surprenante, concerne le BENZO (benzodiazépines). Contrairement aux autres drogues, sa consommation augmente avec l'âge. Ce constat a motivé une recherche complémentaire, et il s'avère que les benzodiazépines sont souvent prescrites comme médicaments pour traiter les troubles du sommeil, l'anxiété ou encore l'épilepsie, des pathologies plus courantes chez les personnes âgées. Cela expliquerait donc pourquoi leur usage ne suit pas la tendance décroissante observée pour la majorité des autres substances.

2 Régression et classification

2.1 Régression linéaire multiple

Dans cette première phase d'analyse prédictive, nous avons appliqué des modèles de régression linéaire multiple afin d'explorer les relations entre variables explicatives (psychométriques et sociodémographiques) et consommation de substances. L'objectif était d'identifier les facteurs ayant un pouvoir prédictif, sans partir d'hypothèses préalables.

2.1.1 Régression multiple générale

Nous avons d'abord construit un modèle global combinant toutes les variables disponibles : traits de personnalité, âge, genre, niveau d'éducation, etc. L'idée était de mesurer leur effet conjugué sur la consommation des différentes drogues *(voir Annexe 12)*.

Les résultats montrent des différences nettes selon les substances. Le cannabis, par exemple, obtient un R^2 de 0.42. Si ce chiffre nous a sembler modeste à première vue, après des recherches nous avons appris que dans les sciences sociales et comportementales, des valeurs de R^2 supérieures à 0.3 sont souvent considérées comme satisfaisantes, en raison de la complexité des comportements humains. Ce premier modèle a servi de point de départ pour affiner l'analyse en séparant les effets psychologiques des facteurs sociaux.

2.1.2 Régression sur les variables psychologiques

Nous avons ensuite isolé les traits de personnalité pour évaluer leur influence spécifique. L'objectif était de voir dans quelle mesure certains comportements peuvent être prédits par des dimensions psychologiques *(voir Annexe 13)*.

Le cannabis reste la substance la mieux prédite par ces variables : son R^2 atteint 0.316. Cela indique que près d'un tiers de la variabilité de sa consommation s'explique par des traits comme la recherche de sensations (SS), l'ouverture (Oscore) ou encore un faible niveau de conscience (Cscore).

Voir Annexe 14 pour les résultats de la régression

D'autres substances comme les champignons hallucinogènes ou le LSD affichent également des R^2 supérieurs à 0.2, ce qui semble confirmer que certains profils psychologiques sont plus associés à l'expérimentation de ces substances. En général, les individus ayant un haut score d'ouverture (Oscore), une forte impulsivité, ou une tendance à rechercher des expériences intenses, sont plus susceptibles d'en consommer.

À l'inverse, les substances courantes comme l'alcool, le café ou le chocolat sont très peu prédictibles par les traits psychologiques, ce qui suggère une influence plus marquée des habitudes sociales ou culturelles.

Pour les drogues plus marginales comme l'héroïne ou le crack, les résultats sont peu significatifs. Cela peut s'expliquer par l'absence de variables importantes (facteurs environnementaux, troubles psychiatriques, etc.) dans notre base de données.

2.1.3 Régression sur les variables sociodémographiques

Enfin, nous avons testé un modèle restreint aux seules variables sociodémographiques : âge, genre, niveau d'éducation. L'objectif était ici de voir si certains produits, faiblement corrélés aux traits de personnalité, pouvaient être mieux expliqués par le contexte social *(voir Annexe 15)*.

Les résultats sont globalement moins convaincants que ceux obtenus avec les variables psychologiques. Peu de substances dépassent un R^2 de 0.1, et certaines, comme le café ou le chocolat, restent pratiquement imprévisibles même avec ces informations.

Toutefois, quelques tendances générales émergent. Les substances illégales ou marginales sont plus souvent consommées par des individus jeunes, parfois moins diplômés, tandis que des produits comme l'alcool ou la nicotine montrent une consommation plus importante chez les personnes âgées et/ou ayant un niveau d'études plus élevé.

Enfin, en comparant directement les résultats sur le cannabis, nous avons constaté que ce dernier est bien mieux expliqué par les variables psychologiques que par les variables sociales. Cela renforce l'idée que certaines substances, bien qu'également soumises à des contextes culturels et législatifs, sont fortement liées à des traits de personnalité.

2.1.4 Conclusion partielle

Ces résultats suggèrent que certaines consommations peuvent être raisonnablement expliquées par des profils psychologiques, tandis que d'autres dépendent de facteurs sociaux ou échappent aux variables disponibles. Pour mieux cerner les liens observés, nous avons ensuite mené une série de régressions simples, ciblées sur des couples spécifiques de variables. Nous détaillerons dans la partie suivante les relations entre impulsivité, recherche de sensations et consommation de cannabis ou de chocolat.

2.2 Régressions simples

2.2.1 Impulsivité et recherche de sensation forte

Dans un premier temps, étudions la potentielle corrélation linéaire entre l'impulsivité et la recherche de sensations fortes. Après une régression simple, on obtient les coefficients $a = 0.623$ et $b = 0$ pour un $R = 0.623$. L'égalité des valeurs entre a et R s'explique par la normalisation préalable des données.

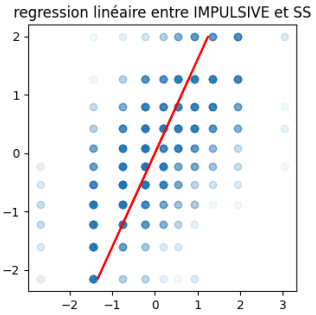


FIGURE 1 – Graphique de la régression IMPULSIVE / SS

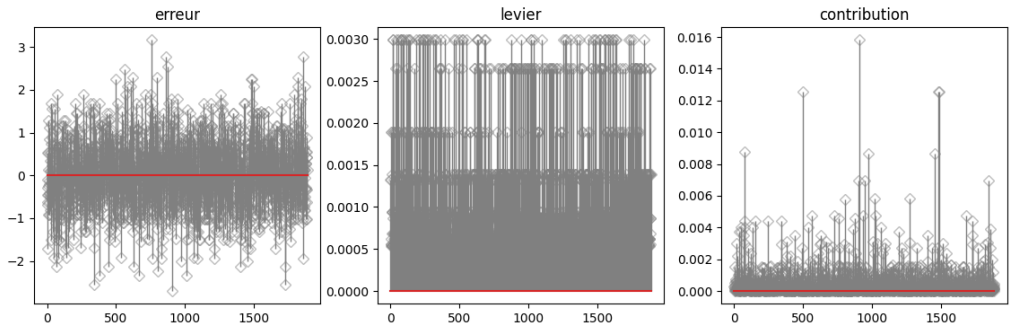


FIGURE 2 – Résultats de la régression IMPULSIVE / SS

A ce stade, nous sommes en mesure de formuler notre première hypothèse :

L'impulsivité et la recherche de sensations fortes sont liés.

Cette hypothèse suggère qu'il existe une relation positive entre l'impulsivité et la recherche de sensations fortes, ce qui signifie que les individus plus impulsifs ont tendance à rechercher des sensations fortes. Nous essaierons de vérifier cette hypothèse avec un test statistique approprié dans la troisième partie de notre analyse. Ce test nous permettra de déterminer si la relation observée est statistiquement significative et de généraliser nos conclusions.

2.2.2 Cannabis et Impulsivité

Dans cette section, nous analysons la relation entre la consommation de cannabis et l'impulsivité. Une régression linéaire simple a été effectuée pour explorer cette relation. Les résultats de cette régression sont les suivants : un coefficient de corrélation $R = 0.31053$ et un coefficient $a = 0.31053$, avec $b = 0$. La valeur du coefficient a indique une relation positive entre l'impulsivité et la consommation de cannabis, suggérant que les individus plus impulsifs ont tendance à consommer davantage de cannabis.

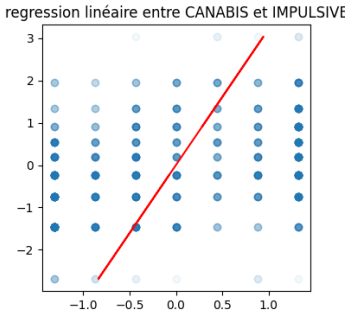


FIGURE 3 – Graphique de la régression Cannabis / Impulsive

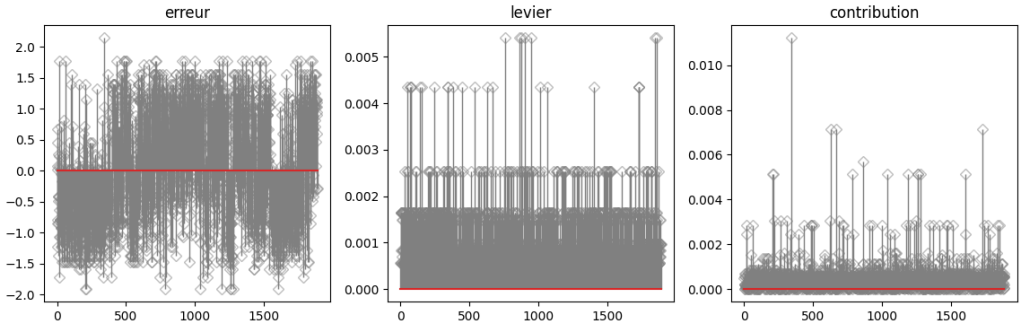


FIGURE 4 – Résultats de la régression Cannabis / Impulsive

Sur la base de ces résultats, nous formulons l'hypothèse suivante :

Les individus présentant un niveau d'impulsivité plus élevé sont plus susceptibles de consommer du cannabis.

Cette hypothèse suggère que l'impulsivité pourrait être un facteur de risque important pour la consommation de cannabis, ce qui pourrait avoir des implications pour les stratégies de prévention ciblant les populations à risque.

2.2.3 Chocolat et impulsivité

Nous examinons ici la relation entre la consommation de chocolat et l'impulsivité. Une régression linéaire simple a été effectuée pour explorer cette relation. Les résultats de cette régression sont les suivants : un coefficient de corrélation $R = 0.02018$ et un coefficient $a = -0.02018$, avec $b = 0$

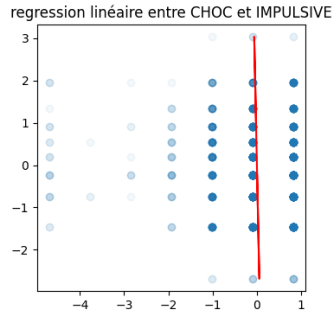


FIGURE 5 – Graphique de la régression CHOC / IMPULSIVE

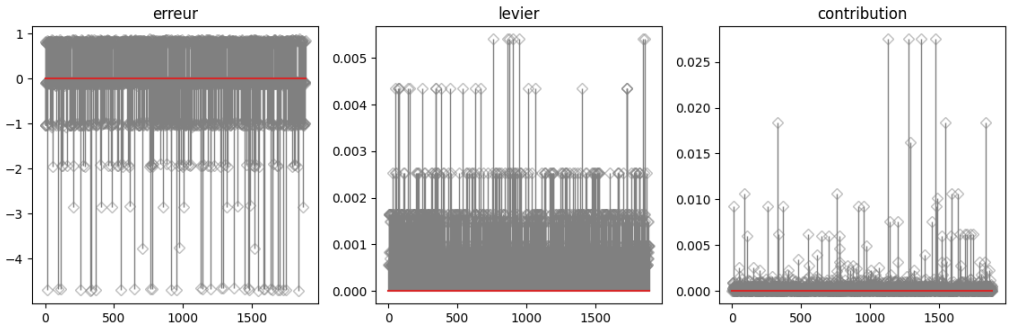


FIGURE 6 – Résultats de la régression CHOC / IMPULSIVE

La valeur du coefficient a indique une relation légèrement négative entre l'impulsivité et la consommation de chocolat, mais cette relation est très faible. Le R^2 étant très faible aussi, nous pouvons formuler l'hypothèse suivante :

L'impulsivité n'a pas d'impact significatif sur la consommation de chocolat.

Cette hypothèse suggère que la consommation de chocolat est probablement influencée par d'autres facteurs, tels que les préférences personnelles par exemple, plutôt que par des traits de personnalité comme l'impulsivité.

3 Tests statistique

Dans le but d'évaluer si la première variable diffère en fonction de la 2ème variable, nous utilisons un test t de Student pour échantillons indépendants. Ce test est adapté car nous comparons la moyenne d'une variable continue (1ère variable) entre deux groupes distincts déterminés préalablement en fonction d'un seuil, ici on prendra la médiane de la variable pour déterminer la limite entre les 2 groupes. L'hypothèse nulle (H_0) suppose qu'il n'existe pas de différence significative entre les moyennes des 2 groupes, tandis que l'hypothèse alternative (H_1) suppose une différence réelle. Pour cela, on sépare les données en 2 groupes, puis nous appliquons le test t. Si la p-value obtenue est inférieure à 0.05, on rejette H_0, ce qui signifie que la première variable est significativement associée à la deuxième variable.

3.1 Impulsivité et recherche de sensation forte

Dans cette première étape de notre analyse statistique, nous cherchons à tester l'existence d'une relation significative entre deux dimensions psychologiques : l'impulsivité et la recherche de sensations fortes. Une première régression effectuée précédemment suggérait un lien notable entre ces deux variables (voir 2.2.1), que nous allons maintenant évaluer statistiquement.

Hypothèses : Nous formulons les hypothèses suivantes :
H_0 : *Il n'existe aucune relation significative entre l'impulsivité et la recherche de sensations fortes.*
H_1 : *Il existe une relation significative entre l'impulsivité et la recherche de sensations fortes.*

Résultats : Les résultats du test de student entre impulsivité et sensation seeking sont les suivants :

R	a	b	erreur	t	p-valeur
0.62312	0.62312	0.0	0.61503	-26.448	0

Interprétation : La p-value très faible (inférieure au seuil de 0.05) indique que nous pouvons rejeter l'hypothèse H_0, ce qui confirme que la relation entre impulsivité et recherche de sensations fortes est statistiquement significative. De plus notre p-valeur est de 0, ce qui peut sembler extrême à première vue cependant cela s'explique par la taille très importante de notre échantillon.

3.2 Cannabis et Impulsivité

Dans cette seconde étape de notre analyse, nous nous intéressons au lien entre un trait de personnalité (l'impulsivité) et un comportement spécifique : la consommation de cannabis. Cette relation avait déjà été suggérée dans notre première régression simple (voir 2.2.2). Nous cherchons ici à vérifier si ce lien est statistiquement significatif.

Hypothèses : On pose les hypothèses suivantes :
H_0 : *Il n'existe aucune relation significative entre l'impulsivité et la consommation de cannabis.*
H_1 : *Il existe une relation significative entre l'impulsivité et la consommation de cannabis.*

Résultats : Les résultats du test de student entre impulsivité et consommation de cannabis sont présentés ci-dessous :

R	a	b	erreur	t	p-valeur
0.45614	0.45614	0.0	0.75826	-21.493	0

Interprétation : La p-valeur est encore une fois très faible (nul) nous permet de rejeter l'hypothèse nulle H_0, ce qui indique que la relation entre impulsivité et consommation de cannabis est statistiquement significative. Le coefficient de corrélation $R = 0.456$ suggère une relation positive modérée : les individus plus impulsifs ont tendance à consommer davantage de cannabis.

Ce résultat conforte l'idée que certains traits de personnalité peuvent prédisposer à l'usage de substances, en particulier celles associées à des comportements de recherche de nouveauté ou de gratification immédiate, comme le cannabis.

3.3 Chocolat et impulsivité

Dans cette dernière sous-partie, nous testons l'hypothèse d'un lien entre le trait d'impulsivité et un comportement de consommation plus banal : celui du chocolat. Bien que cela puisse sembler anodin, ce type de produit est parfois associé à des comportements de gratification immédiate, ce qui justifie notre intérêt.

Hypothèses : Nous formulons les hypothèses suivantes :
H_0 : *Il n'existe aucune relation significative entre l'impulsivité et la consommation de chocolat.*
H_1 : *Il existe une relation significative entre l'impulsivité et la consommation de chocolat.*

Résultats : Les résultats du test de student entre impulsivité et consommation de chocolat sont les suivants :

R	a	b	erreur	t	p-valeur
0.02018	-0.02018	0.0	0.70219	0.527	0.59839

Interprétation : Contrairement aux précédentes analyses, la p-valeur (0.598) est largement supérieure au seuil de 0.05. Cela nous empêche de rejeter l'hypothèse nulle H_0 : il n'y a donc pas de relation statistiquement significative entre impulsivité et consommation de chocolat. Le coefficient de corrélation $R = 0.02$ est très proche de zéro, ce qui confirme l'absence de lien notable entre ces deux variables.

Ces résultats suggèrent que la consommation de chocolat ne dépend pas particulièrement de traits de personnalité tels que l'impulsivité. D'autres facteurs, comme les préférences alimentaires, les habitudes culturelles ou les aspects émotionnels ponctuels, pourraient jouer un rôle plus important.

Conclusion

À travers cette étude, nous avons tenté de mieux comprendre les comportements de consommation de substances psychoactives à partir de données sociodémographiques et psychométriques. Si les usages varient selon l'âge, le genre ou le niveau d'éducation, nos analyses ont surtout mis en lumière le poids significatif de certains traits de personnalité, comme l'impulsivité ou la recherche de sensations fortes, dans la consommation de produits comme le cannabis ou les hallucinogènes. À l'inverse, d'autres substances plus courantes, telles que le chocolat ou le café, semblent davantage guidées par des habitudes sociales que par des profils psychologiques.

Nos régressions, complétées par des tests statistiques rigoureux, confirment certaines intuitions mais elles soulignent aussi les limites inhérentes à ce type d'analyse. En effet, la complexité des comportements humains, les facteurs contextuels non mesurés, ou encore la dimension culturelle et légale des drogues, échappent en partie aux modèles statistiques. Cela nous rappelle qu'un chiffre n'est jamais neutre, et qu'une lecture éthique et nuancée reste nécessaire.

En définitive, si ce travail ne permet pas de dresser un portrait définitif du consommateur de drogue, il propose une lecture plurielle, éclairée par les données, de pratiques aussi diverses que les individus qui les adoptent. Une manière, peut-être, d'alimenter les réflexions actuelles sur les politiques de prévention, de santé publique et de réduction des risques en s'appuyant non sur des jugements, mais sur la compréhension.

Annexes

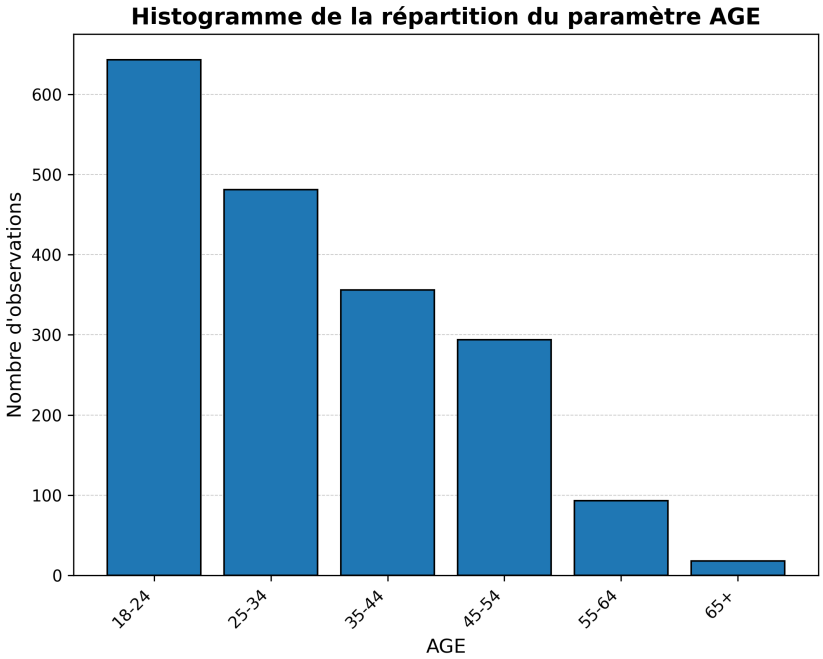


FIGURE 7 – Répartition de l'âge

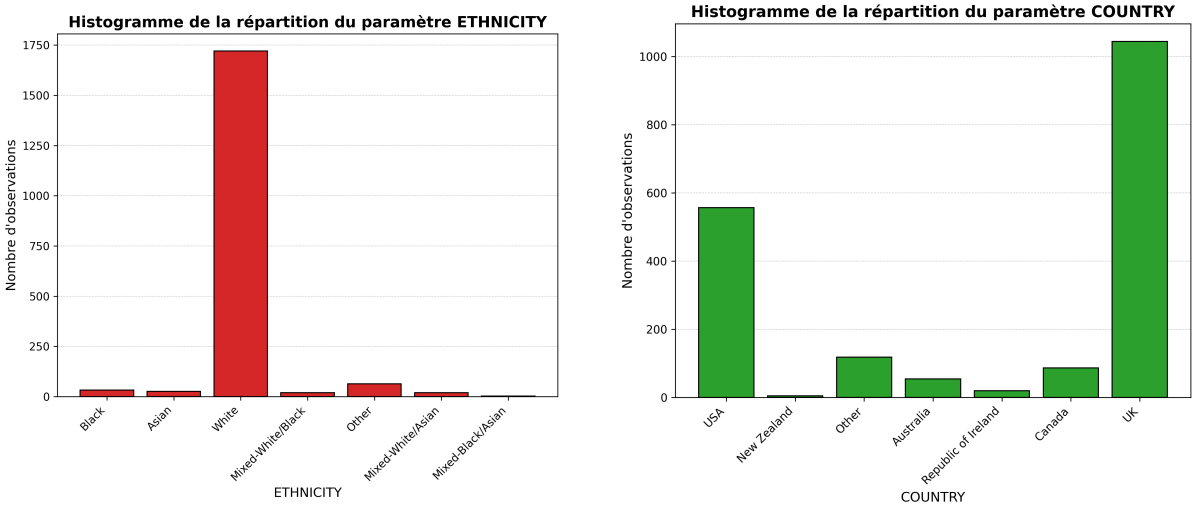


FIGURE 8 – Répartition de l'ethnie et du pays d'origine

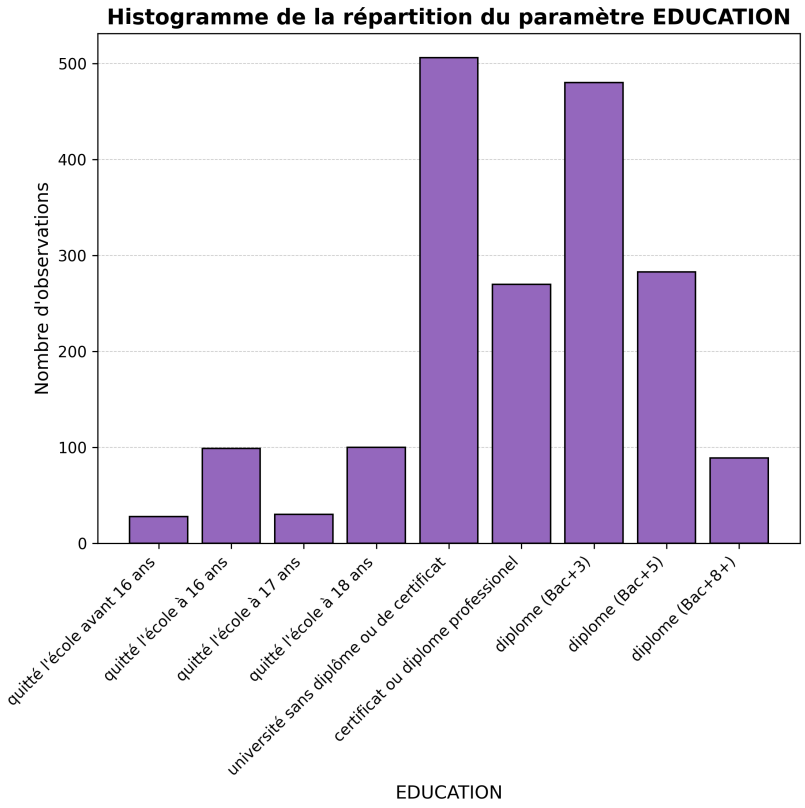


FIGURE 9 – Répartition du niveau d'éducation

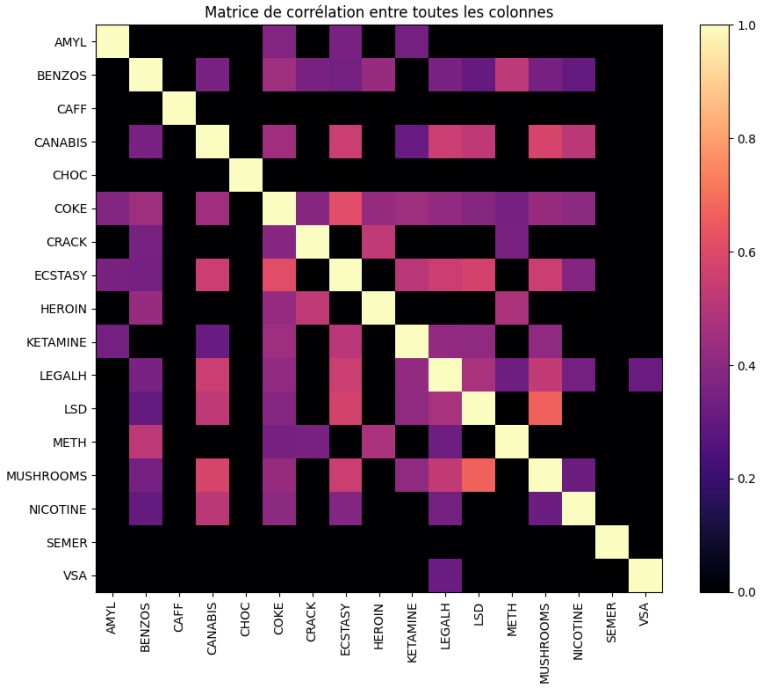


FIGURE 10 – Matrice de corrélation des consommations de drogue

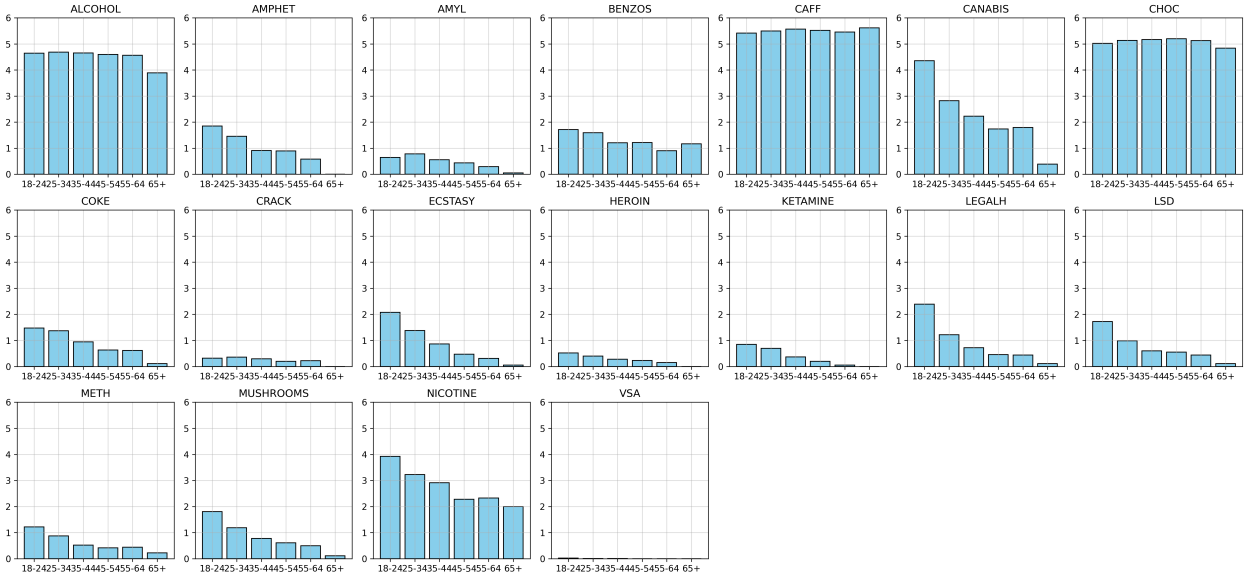


FIGURE 11 – Consommation moyenne en fonction des tranches d'âge

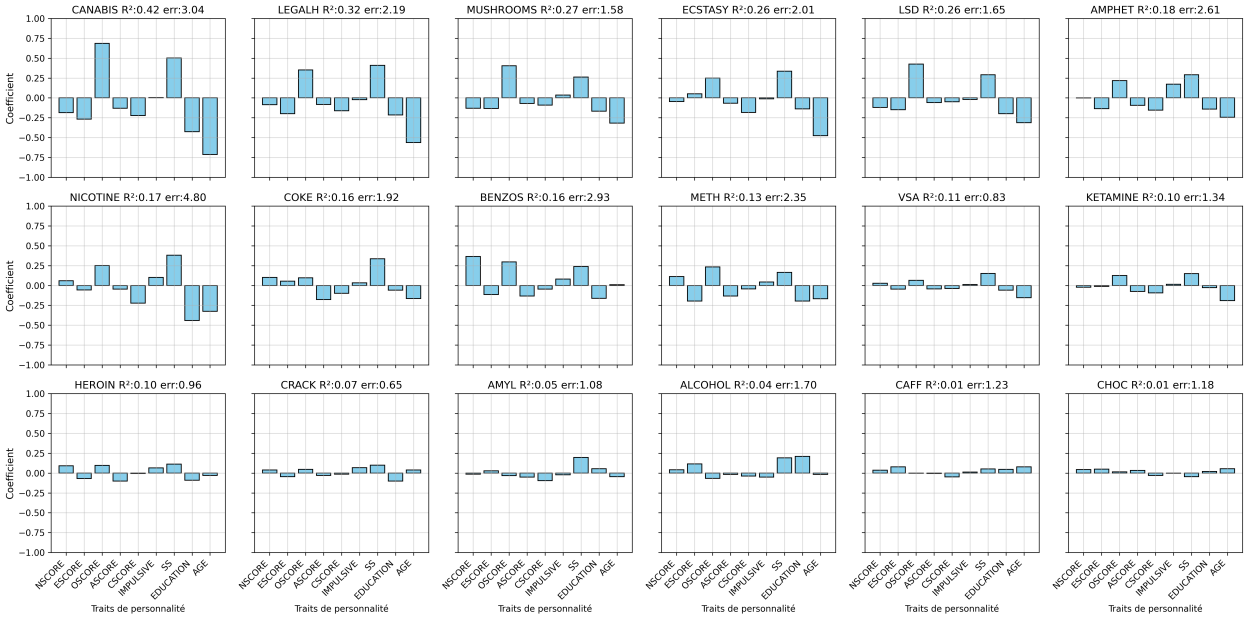


FIGURE 12 – Graphiques des Coefficients socio-psychodémographique de chaque régressions pour chaque substance

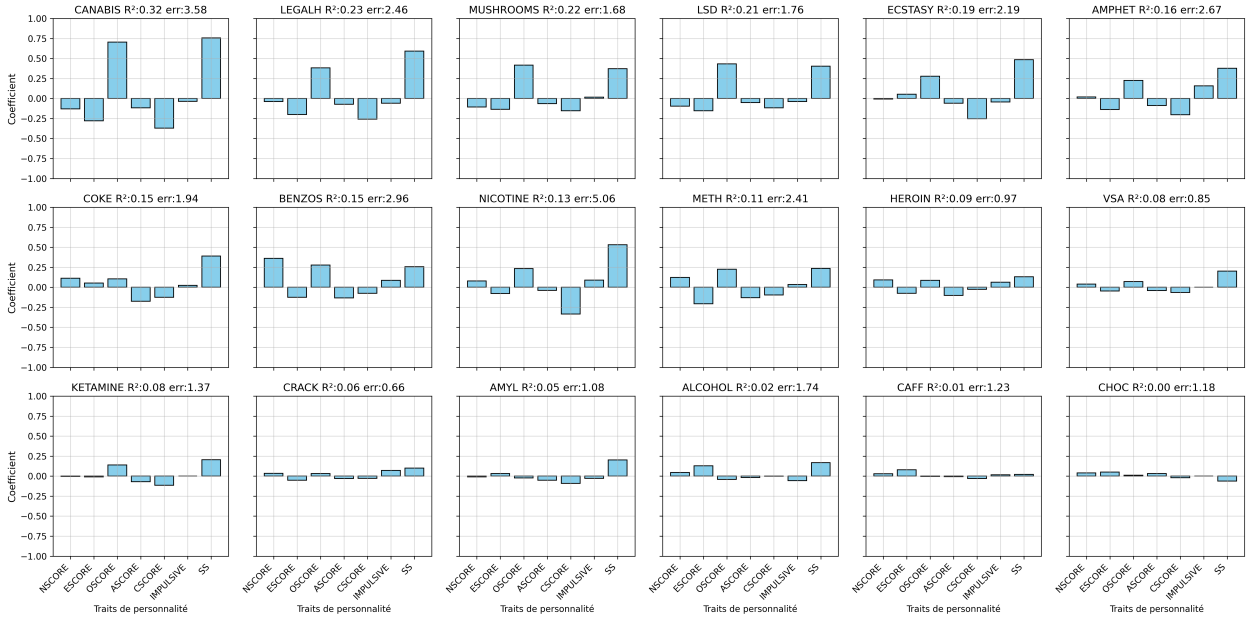
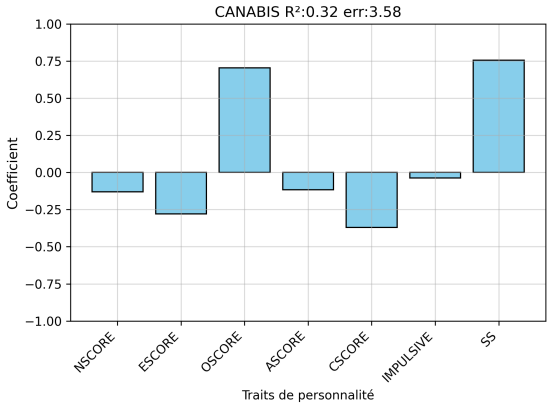


FIGURE 13 – Graphiques des Coefficients psychologique de chaque régressions pour chaque substance



Variable	Coefficient
R^2	0.3161
Erreur (MSE)	3.5764

Variable	Coefficient
NSCORE	-0.131040
ESCORE	0.279279
OSCORE	-0.705459
ASCORE	-0.116361
CSCORE	-0.370929
IMPULSIVE	-0.036630
SS	0.756349

FIGURE 14 – Graphique et tableau des coefficients psychologiques de la régression pour le cannabis

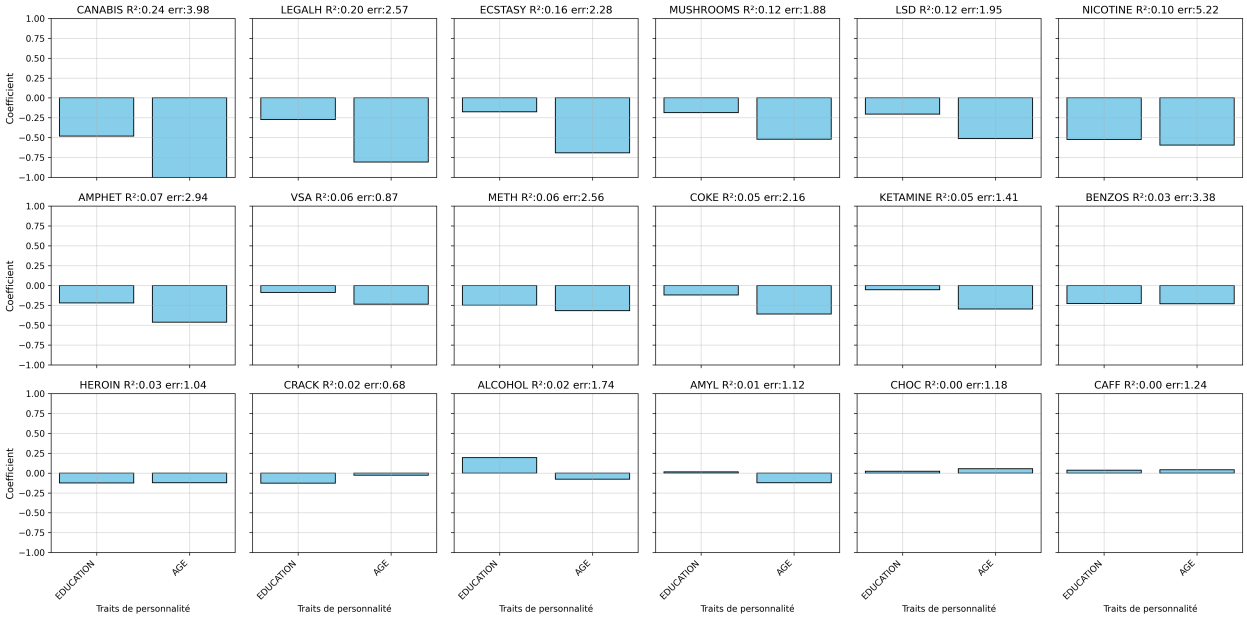


FIGURE 15 – Graphiques des coefficients sociodémographiques pour chaque substance